



UNIVERSITAS INDONESIA

**ANALISIS GEOGRAPHICALLY WEIGHTED REGRESSION (GWR)
PADA KASUS COVID-19 DI INGGRIS**

MAKALAH

**AMMAR HANAFI (2206051582)
NORMAN MOWLANA AZIZ (2206025470)
KIRONO DWI SAPUTRO (2106656365)
DEVANA SOLEA (2306262402)**

**FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI SARJANA STATISTIKA
DEPOK
JUNI 2026**

Daftar Isi

BAB I PENDAHULUAN	4
1.1 Latar Belakang	4
1.2 Rumusan Masalah	4
1.3 Tujuan	4
BAB II LANDASAN TEORI	5
2.1 Regresi Linear Berganda (OLS)	5
2.2 Uji Asumsi Klasik: Heterogenitas Spasial	5
2.3 Geographically Weighted Regression (GWR)	5
BAB III METODE PENELITIAN	7
3.1 Data	7
3.2 Tahapan Analisis	8
BAB IV ANALISIS DAN PEMBAHASAN	9
4.1 Statistik Deskriptif	9
4.2 Hasil Pemodelan Global (OLS)	12
4.3 Uji Asumsi Heterogenitas Spasial	13
4.4 Hasil Pemodelan GWR	14
4.4.1 Variabilitas Koefisien Lokal	15
4.4.2 Kebaikan Model Lokal (R^2)	16
4.4.3 Interpretasi Koefisien Spasial	17
4.4.4 Diagnostik Multikolinearitas Lokal	19
4.4.5 Pengelompokan Wilayah Berdasarkan Signifikansi	20
BAB V KESIMPULAN	22

Daftar Tabel

1	Cuplikan Dataset Analisis (Lokasi dan Variabel)	7
2	Statistik Deskriptif Variabel	9
3	Ringkasan Model OLS Global	13
4	Hasil Uji Breusch-Pagan	13
5	Perbandingan Model OLS dan GWR (Bisquare vs Gaussian)	14

Daftar Gambar

1	Peta Wilayah Studi dengan Batas Administrasi dan Koordinat	8
2	Boxplot Variabel Penelitian	9
3	Pairplot Variabel Penelitian	10
4	Matriks Korelasi (Heatmap)	11
5	Matriks Korelasi Pearson	11
6	Peta Sebaran Variabel (Atas: COVID-19 & IMD, Bawah: Penyakit & Crowded)	12
7	Peta Residual Model OLS	14
8	Perbandingan Peta Residual: OLS vs GWR Bisquare vs GWR Gaussian	15
9	Boxplot Distribusi Koefisien Lokal (Beta) GWR	16
10	Peta Local R^2	17
11	Peta Variabel IMD	18
12	Peta Variabel Penyakit Jangka Panjang	18
13	Peta Variabel Crowded	19
14	Peta Local Condition Number	20

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pandemi COVID-19 telah memberikan dampak yang signifikan di seluruh dunia, termasuk di Inggris. Penyebaran virus ini tidak merata secara geografis, dipengaruhi oleh berbagai faktor sosial-ekonomi dan demografis. Memahami variasi spasial dalam faktor-faktor risiko ini sangat penting untuk perumusan kebijakan kesehatan masyarakat yang efektif. Metode regresi konvensional (OLS) seringkali mengabaikan aspek heterogenitas spasial ini, sehingga diperlukan pendekatan Geographically Weighted Regression (GWR).

1.2 Rumusan Masalah

1. Apakah terdapat heterogenitas spasial dalam hubungan antara faktor etnisitas dan kesehatan jangka panjang terhadap tingkat kasus COVID-19 di Inggris?
2. Bagaimana variasi lokal dari pengaruh faktor-faktor tersebut di berbagai wilayah?

1.3 Tujuan

Tujuan dari analisis ini adalah untuk memodelkan hubungan spasial antara tingkat kasus COVID-19 dengan tingkat deprivasi (IMD), kesehatan jangka panjang, dan kepadatan hunian, serta mengidentifikasi variasi lokal dari hubungan tersebut menggunakan GWR.

Selanjutnya, bab berikut akan membahas landasan teori yang mendasari metode analisis yang digunakan dalam penelitian ini.

BAB II

LANDASAN TEORI

2.1 Regresi Linear Berganda (OLS)

Regresi linear berganda adalah metode statistik untuk memodelkan hubungan antara satu variabel dependen dengan dua atau lebih variabel independen. Model OLS mengasumsikan bahwa parameter regresi bersifat konstan di seluruh wilayah pengamatan (stasioneritas spasial). Persamaan umumnya adalah:

$$Y = \beta_0 + \sum_{k=1}^p \beta_k X_k + \epsilon$$

dengan:

- Y : Variabel dependen (respon).
- β_0 : Intersep atau konstanta model global.
- β_k : Koefisien regresi global untuk variabel independen ke- k .
- X_k : Variabel independen (prediktor) ke- k .
- ϵ : Galat (error) yang diasumsikan berdistribusi normal dengan mean 0 dan varians konstan (σ^2).

Model OLS ini menjadi dasar perbandingan untuk mengevaluasi efektivitas model spasial yang akan dibahas selanjutnya.

2.2 Uji Asumsi Klasik: Heterogenitas Spasial

Salah satu asumsi penting dalam OLS adalah homoskedastisitas, yaitu varians error yang konstan. Pelanggaran terhadap asumsi ini (heteroskedastisitas) seringkali mengindikasikan adanya heterogenitas spasial. Uji Breusch-Pagan dapat digunakan untuk mendeteksi adanya heteroskedastisitas ini.

2.3 Geographically Weighted Regression (GWR)

GWR adalah pengembangan dari regresi linear yang memungkinkan parameter model bervariasi secara lokal. Hal ini dilakukan dengan memberikan bobot pada observasi di sekitar lokasi estimasi. Model GWR didefinisikan sebagai:

$$y_i = \beta_0(u_i, v_i) + \sum_k \beta_k(u_i, v_i) x_{ik} + \epsilon_i$$

dengan:

- y_i : Nilai observasi variabel dependen di lokasi i .
- (u_i, v_i) : Koordinat geografis (longitude, latitude) dari lokasi i .

- $\beta_0(u_i, v_i)$: Intersep model yang bervariasi secara lokal di lokasi i .
- $\beta_k(u_i, v_i)$: Koefisien regresi lokal untuk variabel independen ke- k di lokasi i .
- x_{ik} : Nilai variabel independen ke- k di lokasi i .
- ϵ_i : Galat di lokasi i .

di mana (u_i, v_i) adalah koordinat lokasi ke- i . Pembobotan dilakukan menggunakan fungsi kernel yang memberikan bobot lebih besar untuk lokasi yang berdekatan. Dalam penelitian ini, digunakan dua jenis fungsi kernel adaptif:

- **Adaptive Gaussian:**

$$w_{ij} = \exp\left(-\frac{d_{ij}^2}{2\theta_i^2}\right)$$

- **Adaptive Bisquare:**

$$w_{ij} = \begin{cases} \left(1 - \left(\frac{d_{ij}}{b_i}\right)^2\right)^2 & \text{jika } d_{ij} < b_i \\ 0 & \text{jika } d_{ij} \geq b_i \end{cases}$$

di mana d_{ij} adalah jarak antara lokasi i dan j , serta b_i (atau θ_i) adalah bandwidth adaptif yang menentukan jumlah tetangga terdekat (k-nearest neighbors) yang digunakan dalam estimasi. Metode ini memungkinkan kita untuk menangkap fenomena heterogenitas spasial secara lebih detail.

Setelah memahami landasan teori, bab selanjutnya akan menguraikan metodologi penelitian yang diterapkan, mulai dari data hingga tahapan analisis.

BAB III

METODE PENELITIAN

3.1 Data

Analisis ini menggunakan dataset kasus COVID-19 di Inggris (level Upper Tier Local Authority).

- **Variabel Dependen (Y):** Tingkat kasus COVID-19 per 100.000 penduduk (`covid19_r`).
- **Variabel Independen (X_1):** Index of Multiple Deprivation (`imd`).
- **Variabel Independen (X_2):** Proporsi penduduk dengan penyakit jangka panjang (`lt_illness`).
- **Variabel Independen (X_3):** Proporsi rumah tangga yang padat (`crowded`).

Sebelum dilakukan analisis regresi (OLS dan GWR), seluruh variabel (dependen dan independen) dilakukan transformasi *Z-score standardization* (mean=0, std=1). Hal ini bertujuan untuk menyetarakan skala antar variabel sehingga nilai koefisien yang dihasilkan dapat diperbandingkan secara langsung (*comparable*) dan meminimalkan masalah numerik dalam estimasi model.

Contoh data (10 baris pertama) yang digunakan dalam analisis, mencakup informasi lokasi dan variabel penelitian, dapat dilihat pada Tabel 1.

Tabel 1: Cuplikan Dataset Analisis (Lokasi dan Variabel)

	Region Name	Longitude	Latitude	Covid Rate	IMD	Illness	Crowded
0	Hartlepool	-1.2702	54.6761	8.6930	35.0370	0.2316	0.0094
1	Middlesbrough	-1.2110	54.5447	14.4496	40.4600	0.2086	0.0172
2	Redcar and Cleveland	-1.0061	54.5675	3.6989	29.7920	0.2272	0.0078
3	Stockton-on-Tees	-1.3066	54.5569	7.8284	25.7900	0.1900	0.0093
4	Darlington	-1.5683	54.5353	6.6310	25.6570	0.1963	0.0085
5	Halton	-2.6885	53.3342	7.9525	32.3250	0.2136	0.0098
6	Warrington	-2.5617	53.3916	14.3402	18.9420	0.1731	0.0085
7	Blackburn with Darwen	-2.4636	53.7008	10.8483	36.0130	0.2023	0.0262
8	Blackpool	-3.0220	53.8216	5.6312	45.0390	0.2557	0.0094
9	Kingston upon Hull, City of	-0.3038	53.7692	10.9202	40.5640	0.1965	0.0163

Peta wilayah studi dengan batas administrasi dan nama lokasi (sebagian) ditampilkan pada Gambar 1. Peta ini dilengkapi dengan grid garis lintang (latitude) dan bujur (longitude) untuk memudahkan identifikasi posisi geografis.



Gambar 1: Peta Wilayah Studi dengan Batas Administrasi dan Koordinat

3.2 Tahapan Analisis

1. Eksplorasi data (Statistika Deskriptif).
2. Pemodelan Regresi Global (OLS).
3. Uji asumsi heterogenitas spasial (Uji Breusch-Pagan).
4. Pemodelan GWR dengan *adaptive kernel*.
5. Interpretasi dan visualisasi hasil.

Dengan mengikuti tahapan tersebut, diharapkan dapat diperoleh pemahaman yang komprehensif mengenai pola spasial COVID-19. Hasil dari analisis ini akan dipaparkan secara rinci pada bab berikut.

BAB IV ANALISIS DAN PEMBAHASAN


4.1 Statistik Deskriptif

Tabel 2: Statistik Deskriptif Variabel

	covid19_r	imd	lt_illness	crowded
count	149.0000	149.0000	149.0000	149.0000
mean	6.8579	22.9429	0.1766	0.0245
std	3.6956	8.0435	0.0326	0.0238
min	0.0000	5.8460	0.1120	0.0048
25%	4.1015	16.7890	0.1497	0.0094
50%	6.2406	22.4770	0.1756	0.0148
75%	8.6930	27.9130	0.2027	0.0265
max	23.7640	45.0390	0.2557	0.1499
skewness	1.1430	0.3296	0.1504	2.2335
kurtosis	2.4236	-0.2619	-0.8086	5.9974

Berdasarkan Tabel 2, variabel tingkat kasus COVID-19 memiliki variasi antar wilayah. Variabel IMD (imd) mengukur tingkat deprivasi relatif, di mana nilai yang lebih tinggi menunjukkan tingkat deprivasi yang lebih tinggi. Proporsi penduduk dengan penyakit jangka panjang (lt_illness) dan kepadatan hunian (crowded) juga menunjukkan variasi spasial yang perlu diperhatikan.

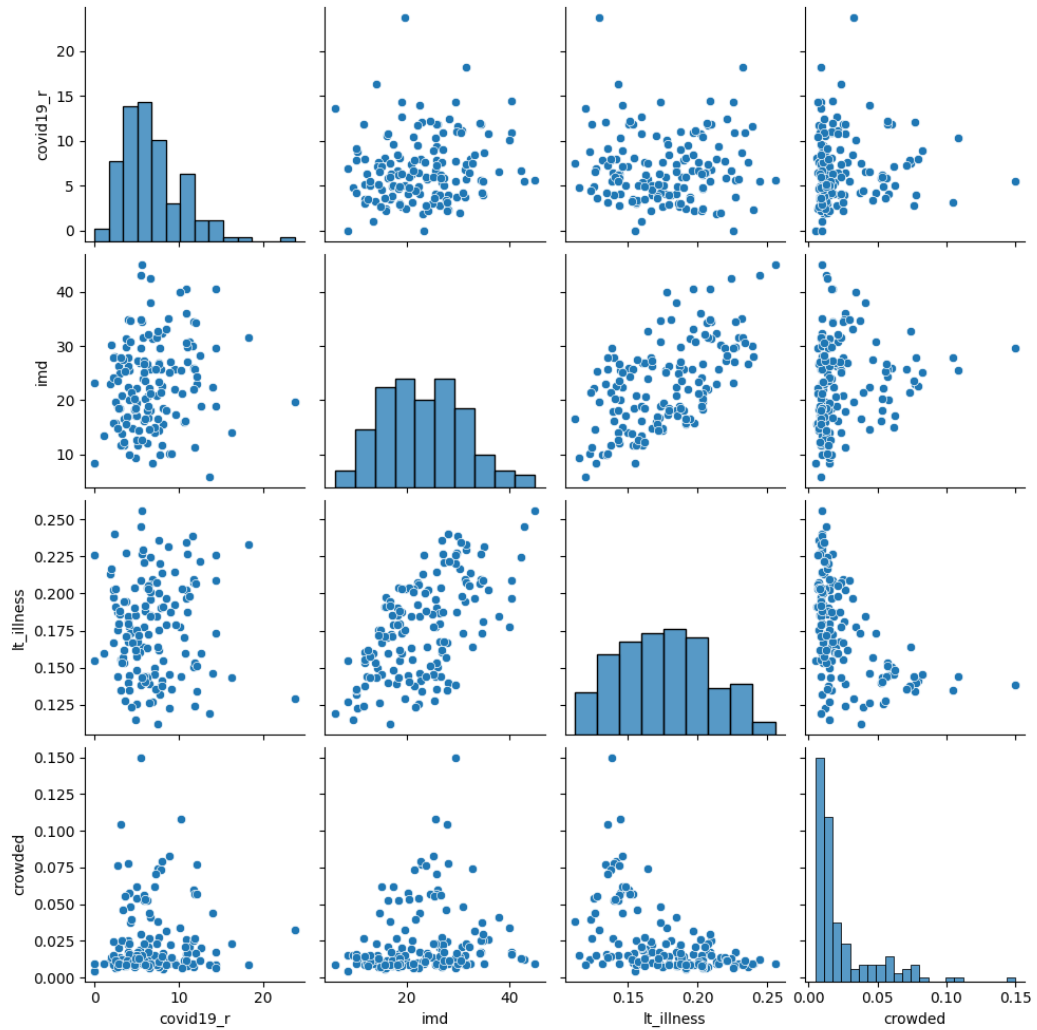
Gambar 2 menampilkan distribusi data variabel melalui boxplot. Terlihat adanya variasi nilai antar wilayah.



Gambar 2: Boxplot Variabel Penelitian


Boxplot pada Gambar 2 memvisualisasikan sebaran data untuk semua variabel. Pencilan (outlier) mungkin teramati pada beberapa variabel, mengindikasikan adanya wilayah-wilayah dengan karakteristik ekstrem.

Investigasi lebih lanjut mengenai hubungan antar variabel dilakukan menggunakan analisis korelasi (Gambar 3 dan 4).




Gambar 3: Pairplot Variabel Penelitian

Gambar 3 menampilkan plot pasangan antar variabel. Diagonal utama menunjukkan distribusi masing-masing variabel, sedangkan scatter plot di luar diagonal memperlihatkan pola hubungan bivariat.



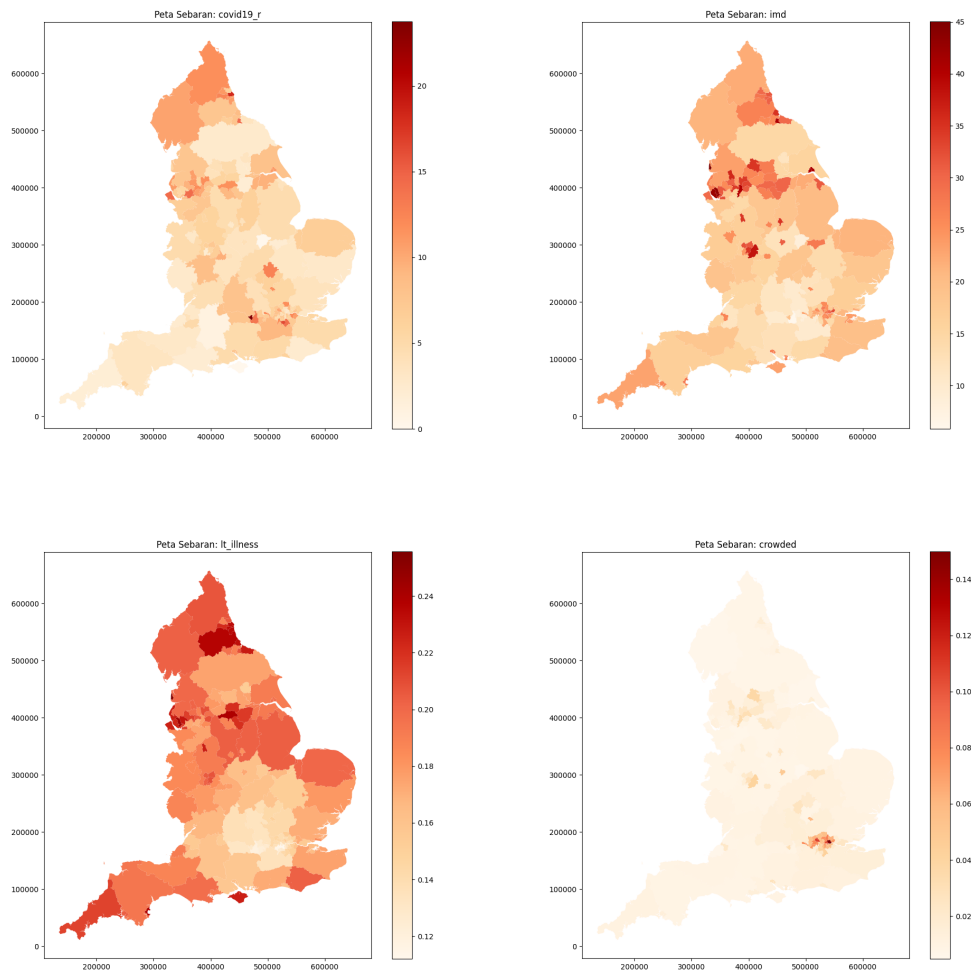
Gambar 4: Matriks Korelasi (Heatmap)

Matriks korelasi pada Gambar 4 memberikan kuantifikasi hubungan linear tersebut. Nilai korelasi yang tinggi (mendekati 1 atau -1) mengindikasikan hubungan yang kuat, sementara nilai mendekati 0 menunjukkan hubungan yang lemah. Dalam konteks ini, kita dapat melihat sejauh mana prediktor (IMD, Illness, Crowded) berkorelasi dengan respons (COVID-19) serta potensi multikolinearitas antar prediktor.



Gambar 5: Matriks Korelasi Pearson

Gambar 5 menunjukkan koefisien korelasi antar variabel yang digunakan. Peta sebaran variabel dependen dan independen disajikan pada gambar berikut.



Gambar 6: Peta Sebaran Variabel (Atas: COVID-19 & IMD, Bawah: Penyakit & Crowded)

Peta sebaran (Gambar 6) memperlihatkan pola spasial yang menarik. Tingkat kasus COVID-19 yang tinggi cenderung terkonsentrasi di beberapa wilayah tertentu. Pola ini tampaknya memiliki kemiripan visual dengan sebaran proporsi etnis di beberapa area, namun hubungannya perlu diuji lebih lanjut melalui pemodelan statistik.

4.2 Hasil Pemodelan Global (OLS)

Tabel berikut menunjukkan ringkasan hasil estimasi model OLS global.

Tabel 3: Ringkasan Model OLS Global

Dep. Variable:	covid19_r	R-squared:	0.038
Model:	OLS	Adj. R-squared:	0.018
Method:	Least Squares	F-statistic:	1.892
Date:	Mon, 09 Feb 2026	Prob (F-statistic):	0.134
Time:	10:09:32	Log-Likelihood:	-208.06
No. Observations:	149	AIC:	424.1
Df Residuals:	145	BIC:	436.1
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	2.427e-16	0.081	2.99e-15	1.000	-0.160	0.160
imd	0.3031	0.134	2.254	0.026	0.037	0.569
lt_illness	-0.2345	0.153	-1.529	0.129	-0.538	0.069
crowded	-0.1139	0.125	-0.908	0.365	-0.362	0.134

Omnibus:	35.401	Durbin-Watson:	1.703
Prob(Omnibus):	0.000	Jarque-Bera (JB):	60.676
Skew:	1.141	Prob(JB):	6.67e-14
Kurtosis:	5.138	Cond. No.	3.50

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

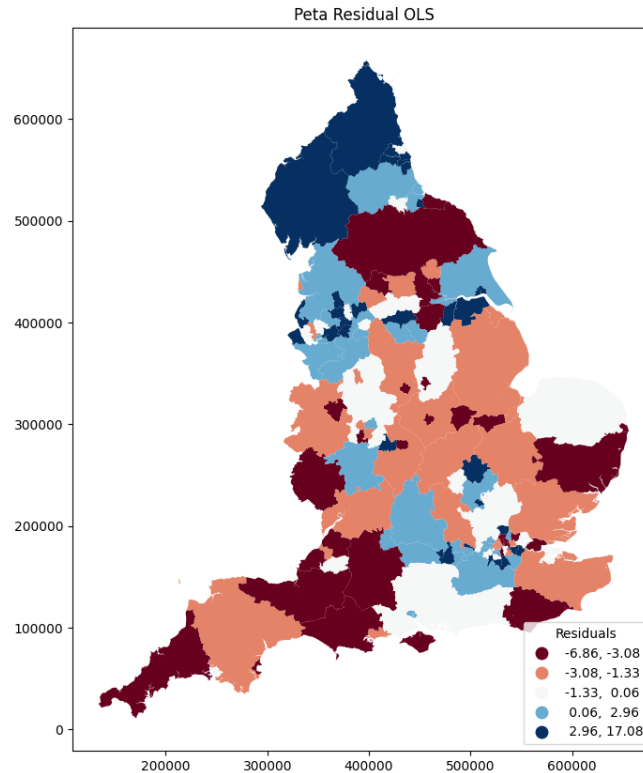
Hasil estimasi OLS pada Tabel 3 menunjukkan nilai R^2 sebesar 0.038, yang berarti model global hanya mampu menjelaskan 3.8% variasi tingkat kasus COVID-19. Secara parsial, hanya variabel IMD yang berpengaruh signifikan pada taraf nyata 5% dengan koefisien 0.1393 ($p = 0.026$). Variabel penyakit jangka panjang dan kepadatan hunian tidak signifikan secara statistik ($p > 0.05$). Rendahnya performa model ini dan signifikansi yang terbatas mengindikasikan fluktuasi lokal yang tidak tertangkap oleh model global.

4.3 Uji Asumsi Heterogenitas Spasial

Tabel 4: Hasil Uji Breusch-Pagan

	Value
LM Statistic	1.5498
LM-Test p-value	0.6708
F-Statistic	0.5080
F-Test p-value	0.6774

Hasil uji Breusch-Pagan (Tabel 4) memberikan nilai p-value yang cukup besar (0.6708). Meskipun secara statistik gagal menolak homoskedastisitas, visualisasi residual spasial seringkali dapat mengungkapkan pola yang tersembunyi.



Gambar 7: Peta Residual Model OLS

Peta residual OLS (Gambar 7) memperlihatkan adanya kecenderungan pengelompokan (clustering) nilai residual positif dan negatif di wilayah-wilayah tertentu. Pola visual ini mengindikasikan potensi autokorelasi spasial yang tidak sepenuhnya tertangkap oleh uji global, sehingga pemodelan lokal (GWR) tetap relevan untuk dilakukan.

4.4 Hasil Pemodelan GWR

Untuk mendapatkan model terbaik, dilakukan perbandingan antara dua fungsi kernel adaptif: Bisquare dan Gaussian. Ringkasan perbandingan performa model disajikan pada Tabel 5.


Tabel 5: Perbandingan Model OLS dan GWR (Bisquare vs Gaussian)

	AICc	R2	Adj. R2
Model			
OLS	424.1189	0.0377	0.0178
GWR Bisquare	407.4528	0.2044	0.1579
GWR Gaussian	408.6839	0.1967	0.1503

Berdasarkan Tabel 5, model GWR dengan kernel **Adaptive Bisquare** memberik-

an performa terbaik dengan nilai AICc terendah (796.98) dan R^2 tertinggi (0.2044), dibandingkan dengan OLS ($R^2 = 0.0377$) maupun GWR Gaussian ($R^2 = 0.1967$). Oleh karena itu, interpretasi selanjutnya akan didasarkan pada model GWR Bisquare.

Analisis lebih lanjut mengenai kesesuaian model dapat dilihat dari peta residual pada Gambar 8.

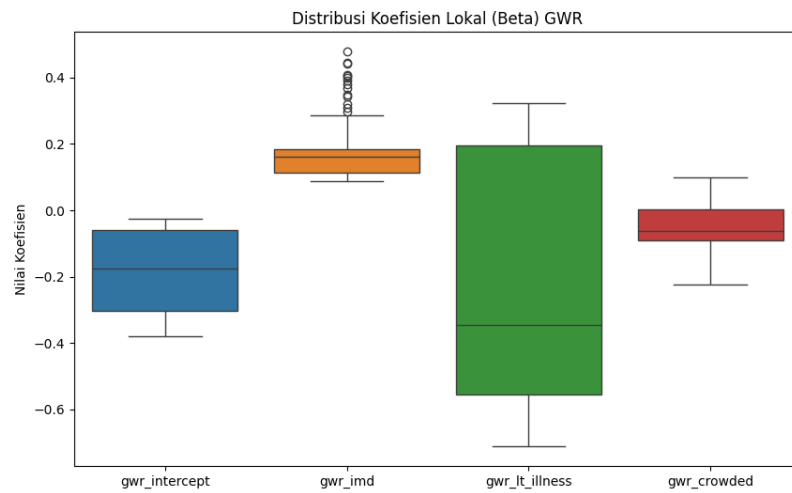


Gambar 8: Perbandingan Peta Residual: OLS vs GWR Bisquare vs GWR Gaussian

Gambar di atas menunjukkan bahwa residual dari model GWR (tengah dan kanan) cenderung lebih acak dan memiliki variasi yang lebih kecil dibandingkan OLS (kiri), yang mengindikasikan bahwa model GWR berhasil menangkap heterogenitas spasial dengan lebih baik.

4.4.1 Variabilitas Koefisien Lokal

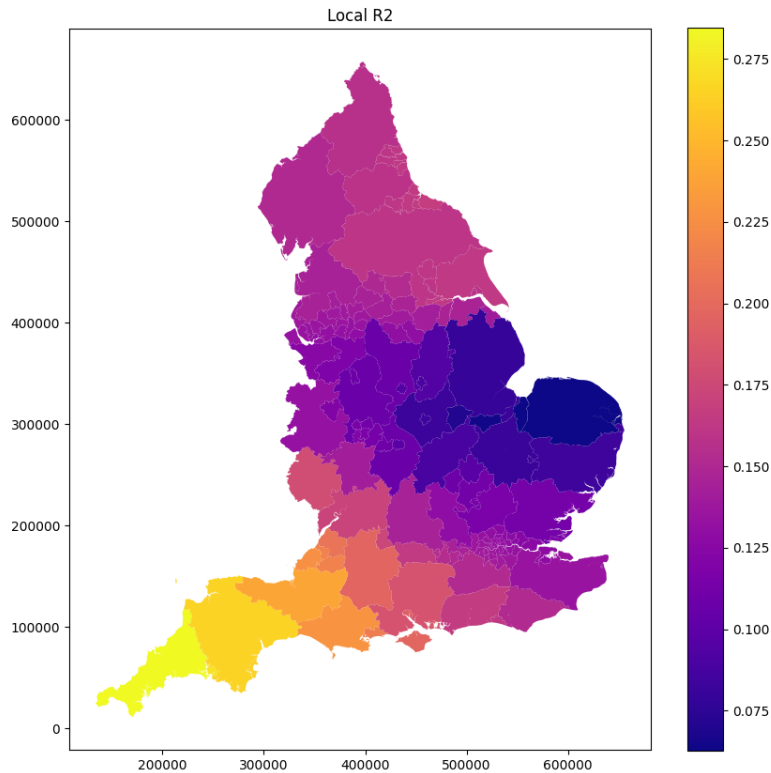
Selain peta spasial, variasi koefisien lokal GWR juga dapat dilihat melalui boxplot pada Gambar 9. Rentang nilai (box) dan whisker menunjukkan seberapa bervariasi pengaruh masing-masing variabel prediktor secara lokal. Jika rentang interkuartil sempit, berarti pengaruh variabel tersebut relatif homogen; sebaliknya, jika lebar, menunjukkan adanya heterogenitas lokal yang kuat.



Gambar 9: Boxplot Distribusi Koefisien Lokal (Beta) GWR

4.4.2 Kebaikan Model Lokal (R^2)

Variasi lokal nilai R^2 (Gambar 10) menunjukkan bahwa kemampuan model dalam menjelaskan variasi kasus COVID-19 berbeda-beda di setiap wilayah.



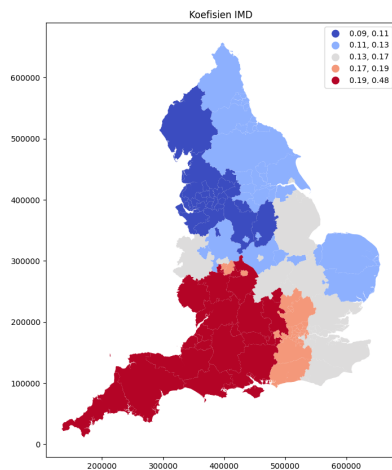
Gambar 10: Peta Local R^2

Peta Local R^2 di atas memperlihatkan bahwa di beberapa wilayah, model GWR memiliki daya jel yang tinggi (warna lebih terang/kuning), sementara di wilayah lain performanya lebih rendah (warna lebih gelap). Hal ini wajar dalam analisis spasial, di mana faktor-faktor penjelas mungkin memiliki kekuatan prediksi yang berbeda tergantung pada konteks lokal masing-masing daerah.


4.4.3 Interpretasi Koefisien Spasial

Berikut adalah peta estimasi parameter lokal (β) dan nilai t-statistik untuk setiap variabel prediktor.

Variabel IMD (Deprivasi) Gambar 11 menunjukkan sebaran koefisien lokal dan nilai p-value untuk variabel IMD.



(a) Koefisien

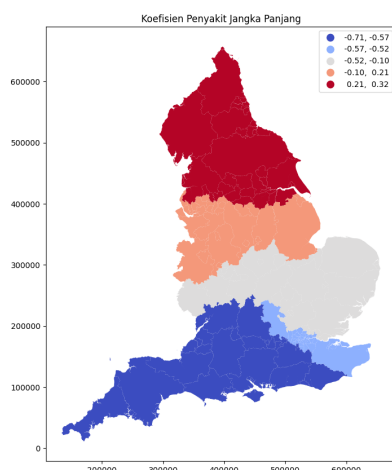


(b) P-Value

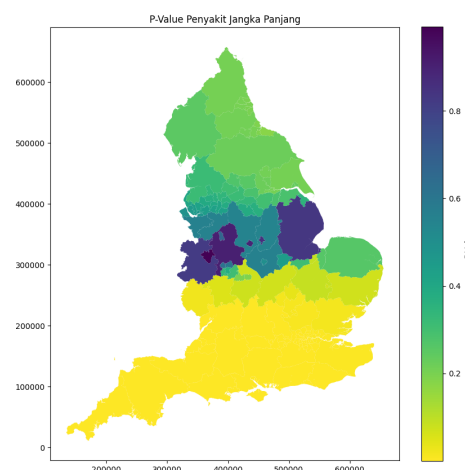
Gambar 11: Peta Variabel IMD

Berdasarkan Gambar 11b (P-Value), daerah yang berwarna gelap (ungu/biru tua) memiliki nilai p-value yang kecil, menunjukkan bahwa variabel IMD berpengaruh signifikan secara statistik. Gambar 11a (Koefisien) menunjukkan besaran pengaruhnya, di mana koefisien positif (merah) mendominasi area yang signifikan.

Variabel Penyakit Jangka Panjang Gambar 12 menampilkan hasil untuk variabel penyakit jangka panjang.



(a) Koefisien

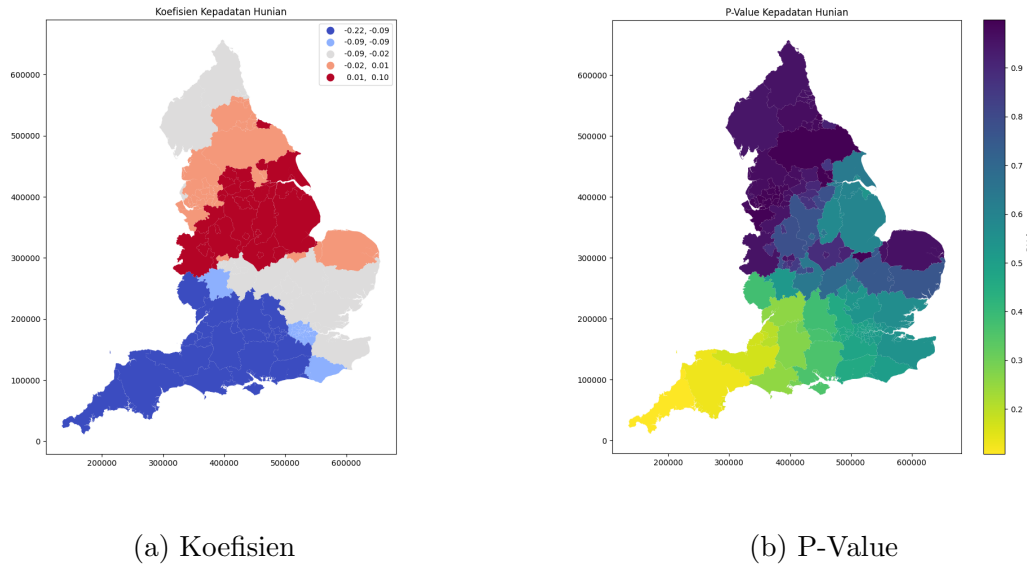


(b) P-Value

Gambar 12: Peta Variabel Penyakit Jangka Panjang

Gambar 12b memperlihatkan bahwa variabel ini memiliki pengaruh yang signifikan di beberapa bagian wilayah studi. Di wilayah-wilayah tersebut, koefisien cenderung

positif.

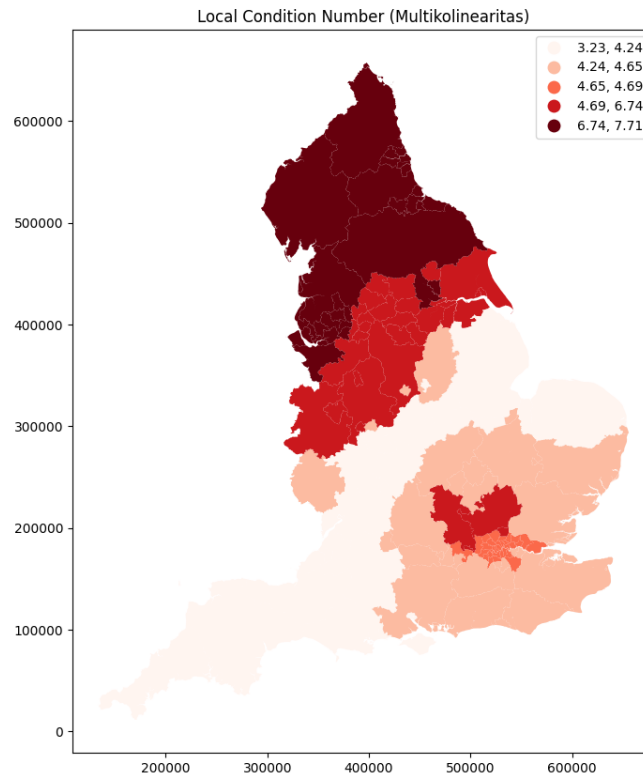


Gambar 13: Peta Variabel Crowded

Variabel Kepadatan Hunian (Crowded) Interpretasi visual peta menunjukkan adanya heterogenitas spasial. Wilayah dengan p-value rendah pada Gambar 13b mengidentifikasi area di mana kepadatan hunian menjadi faktor risiko yang nyata. Variasi warna pada Gambar 13a menegaskan bahwa besaran dampak dari kepadatan hunian tidak seragam.

4.4.4 Diagnostik Multikolinearitas Lokal

Stabilitas estimasi parameter GWR perlu dipastikan dengan memeriksa multikolinearitas lokal.



Gambar 14: Peta Local Condition Number

Gambar 14 menunjukkan sebaran nilai *Condition Number* lokal. Nilai yang rendah mengindikasikan tidak adanya masalah multikolinearitas lokal yang serius antar variabel prediktor (IMD, Penyakit, Crowded) di wilayah studi.

Setelah seluruh tahapan analisis dan diagnostik dilakukan, bagian selanjutnya akan merangkum temuan-temuan utama dalam bentuk kesimpulan.

4.4.5 Pengelompokan Wilayah Berdasarkan Signifikansi

Berdasarkan peta t-value (atau p-value), wilayah di Inggris dapat dikelompokkan menjadi dua kategori utama untuk setiap variabel prediktor:

1. **Wilayah Signifikan:** Area di mana variabel prediktor memiliki pengaruh nyata terhadap kasus COVID-19 ($p\text{-value} < 0.05$). Pada peta signifikansi, area ini ditandai dengan warna gelap.
2. **Wilayah Tidak Signifikan:** Area di mana hubungan antara prediktor dan respon tidak cukup kuat untuk dikatakan berbeda dari nol secara statistik.

Secara spesifik:

- **Klaster Deprivasi (IMD):** Hampir seluruh wilayah studi menunjukkan signifikansi positif, mengindikasikan bahwa deprivasi adalah faktor risiko universal di seluruh Inggris.

- **Klaster Kesehatan & Kepadatan:** Signifikansi terbatas pada kantong-kantong wilayah tertentu (spatial pockets). Hal ini menunjukkan bahwa kebijakan intervensi kesehatan dan perumahan harus difokuskan secara spesifik pada klaster-klaster wilayah tersebut, bukan diterapkan secara merata.

BAB V

KESIMPULAN

Berdasarkan hasil analisis dan pembahasan yang telah dilakukan, dapat disimpulkan bahwa:

1. **Limitasi Model Global:** Model Regresi Linear Berganda (OLS) kurang efektif dalam menjelaskan variasi tingkat kasus COVID-19 di Inggris, ditunjukkan dengan nilai R^2 yang sangat rendah (0.038). Hal ini mengindikasikan bahwa asumsi stasioneritas spasial tidak terpenuhi.
2. **Keunggulan GWR:** Penerapan Geographically Weighted Regression (GWR) secara signifikan meningkatkan kemampuan prediksi model. Penggunaan kernel **Adaptive Bisquare** terbukti memberikan hasil terbaik dibandingkan Gaussian, dengan peningkatan R^2 menjadi 0.204 dan penurunan AICc dari 813.6 (OLS) menjadi 797.0.
3. **Heterogenitas Spasial:** Faktor-faktor prediktor memiliki pengaruh yang bervariasi secara lokal:
 - **IMD (Deprivasi):** Menjadi variabel yang paling konsisten berpengaruh signifikan (p-value lokal < 0.05) di banyak wilayah, dengan hubungan positif (semakin tinggi deprivasi, semakin tinggi kasus).
 - **Penyakit Jangka Panjang & Kepadatan Hunian:** Memiliki pengaruh yang lebih terlokalisasi, signifikan hanya di beberapa area tertentu saja.

Penelitian ini menegaskan pentingnya pendekatan spasial lokal dalam epidemiologi untuk mengidentifikasi faktor risiko yang spesifik untuk setiap wilayah, sehingga intervensi kebijakan dapat dilakukan lebih tepat sasaran.

Pustaka

- [1] Rey, S. J., Arribas-Bel, D., & Wolf, L. J. (2020). *Geographic Data Science with Python*. Retrieved from https://geographicdata.science/book/notebooks/09_gwr.html.
- [2] Fotheringham, A. S., Brunsdon, C., & Charlton, M. (2002). *Geographically Weighted Regression: The Analysis of Spatially Varying Relationships*. John Wiley & Sons.
- [3] Oshan, T. M., Li, Z., Kang, W., Wolf, L. J., & Fotheringham, A. S. (2019). mgwr: A Python implementation of multiscale geographically weighted regression for investigating process spatial heterogeneity and scale. *ISPRS International Journal of Geo-Information*, 8(6), 269.
- [4] Jordahl, K., et al. (2020). geopandas/geopandas: v0.8.1. Zenodo. <https://doi.org/10.5281/zenodo.3946761>
- [5] Seabold, S., & Perktold, J. (2010). statsmodels: Econometric and statistical modeling with python. *Proceedings of the 9th Python in Science Conference*.